# HIVE



Le Data Warehouse de Hadoop

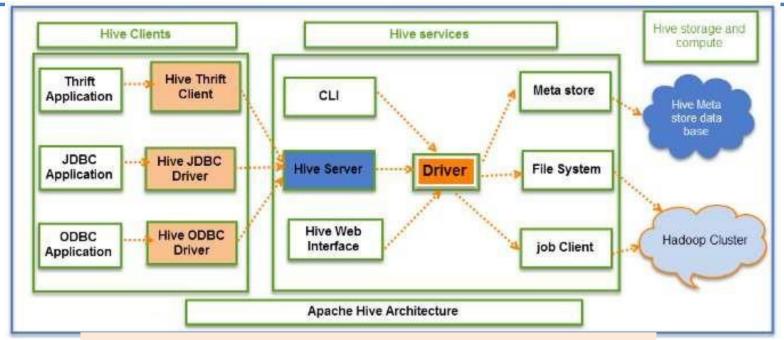
### **Hive: Introduction**

- Hive est un projet né au sein de Facebook et repris par la fondation Apache.
- Apache Hive représente une surcouche analytique à Hadoop
- Il représente aussi une couche d'abstraction aux données HDFS sous forme d'un modèle tabulaire (lignes, colonnes)
- Hive permet de traiter des données structurées dans Hadoop.
- Il est utilisé par différentes entreprises, par exemple, **Amazon** l'utilise dans **Amazon Elastic MapReduce** (*outil AWS de traitement et d'analyse de données*)
- Il a un langage de requête **HiveQL** ou **HQL** proche de SQL (*sélection*, *jointure*, *agrégation*, *union*, *sous-requêtes*)
- La principale différence entre **HiveQL** et **SQL** est qu'une requête Hive s'exécute sur Hadoop plutôt que sur une BD relationnelle.
- Hive prend en charge les fonctions et procédures **java/scala** définies par l'utilisateur pour étendre ses fonctionnalités.

### **Hive: Introduction**

- Une requête **HiveQL** est transformée en une série de jobs **MapReduce** exécutés sur le cluster Hadoop afin de récupérer un jeu de résultat tabulaire.
- **HiveQL** décharge l'utilisateur de la complexité de la programmation MapReduce. Il réutilise les concepts familiers de BD relationnelle (*tables, lignes, colonnes, schémas, etc*) pour faciliter l'apprentissage.
- Hive supporte plusieurs formats de fichiers: **TEXTFILE**, **SEQUENCEFILE**, **ORC**, **RCFILE** (*Record Columnar File*), **PARQUET**, ...etc.
- Les schémas de BDs sont gérés par le MetaStore qui englobe un service qui permet aux clients (applications clientes) d'avoir les métadonnées des tables déclarées dans Hive.
- Le **metastore** persiste ces métadonnées dans une BD **Apache Derby** (*SGBD* développé en Java).

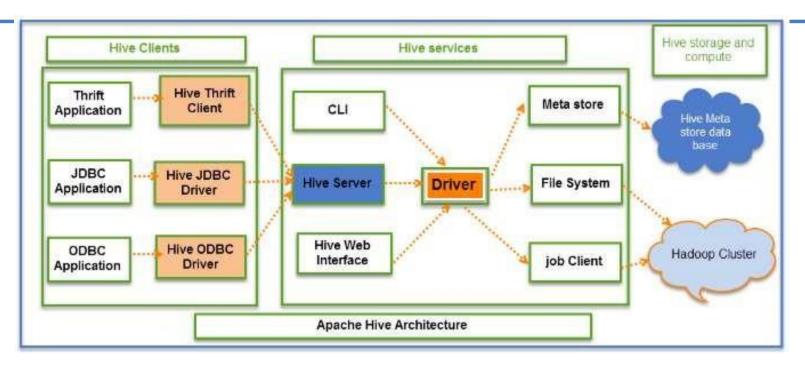
### **Hive: Architecture**



https://www.guru99.com/introduction-hive.html

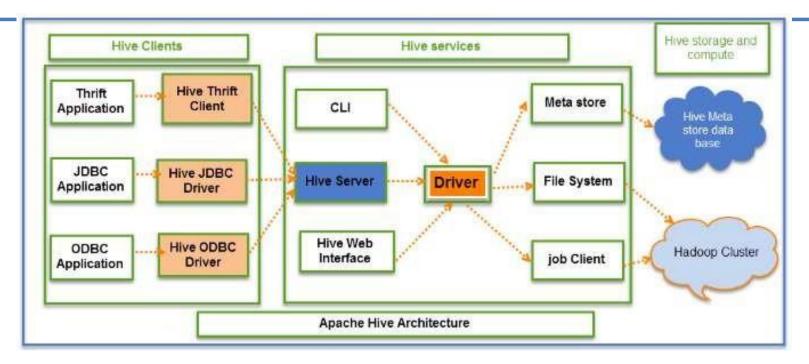
- Clients Hive: Hive supporte toute application (C++, Java, Python, ...) utilisant JDBC, Thrift ou ODBC drivers.
- Services Hive: Cette couche gère les interactions avec l'utilisateur via :
  - Une interface de commandes en ligne (CLI): C'est le shell Hive
  - Une interface web de Hive, dans Cloudera Quickstart: Hue (Hadoop User Experience )
  - Hive Server lorsqu'il s'agit d'applications (JDBC, ODBC ou Thrift).

### **Hive: Architecture**



- Les requêtes utilisateur sont reçues par le **Driver** qui inclut :
  - Un **compilateur** (**Compiler**) : vérifie la syntaxe et la sémantique de la requête en utilisant les schémas stockés dans le **Meta Store**.
  - Un **optimiseur** (**Optimizer**) qui génère le plan d'exécution optimal de la requête sous forme d'un DAG (Directed Acyclic Graph)
  - Un **moteur d'exécution (Execution Engine**) qui exécute le plan d'exécution sous forme d'une série de jobs MapReduce.

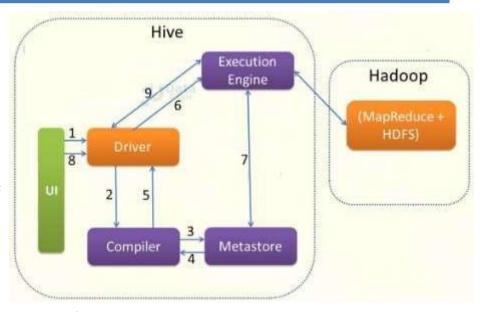
### **Hive: Architecture**



- Stockage et traitement Hive:
- Le **MetaStore** est le référentiel central des *métadonnées* Apache Hive. Il stocke les métadonnées des **tables** Hive (*schéma*, *emplacement des fichiers*, ...) et des **partitions** dans une BD relationnelle (*Mysql*, *Derby*, ...). Il consiste en deux unités fondamentales:
  - \* Un service qui fournit un accès métastore aux autres services Apache Hive.
  - \* Stockage des métadonnées Hive sur disque (Mysql ou Derby).
- Les données chargées dans les tables Hive et les résultats des requêtes seront stockés dans le cluster Hadoop (HDFS)

# Hive: Etapes Traitement des données dans Hive

- 1. La requête utilisateur est soumise au **Driver**
- 2. Le **Driver** envoie la requête au compilateur afin d'avoir le plan d'exécution.
- 3.4. Le **compilateur** interagit avec le **MetaStore** pour avoirs les métadonnées des tables utilisées dans la requête.



- 5. Le **compilateur** (**+optimiseur**) crée le plan d'exécution (*sous forme d'un DAG*(*Directed Acyclic Graph*) où chaque arc représente un job map/reduce job, une opération sur HDFS ou une opération sur les metadonnées) et l'envoie au **Driver**.
- 6. Le **Driver** envoie le plan d'exécution au **Moteur d'exécution** qui va l'exécuter sur le cluster en tant qu'une **série de jobs MapReduce**. Les résultats seront **stockés** dans HDFS.
- 7. Le **Moteur d'exécution** interagit avec le **MetaStore** lorsqu'il s'agit d'une requête DDL
- 8-9. L'application cliente récupère les résultats depuis le **Driver**. Le **moteur d'exécution** communique avec les **Data Nodes** (**via le NameNode**) afin d'avoir les résultats qu'il passera ensuite à l'application cliente.

# **Hive: Configuration**

• Les paramètres de configuration de **Hive** sont dans le fichier **hive-site.xml** (/etc/hive/conf/hive-site.xml), par exemple:

```
Chaîne de connexion JDBC à la BD du Metastore
cproperty>
 <name>iavax.ido.option.ConnectionURL</name>
 <value>jdbc:mysql://127.0.0.1/metastore?createDatabaseIfNotExist=true</value>
 <description>JDBC connect string for a JDBC metastore</description>
</property>
                                            Le classe du driver JDBC
property>
  <name>javax.ido.option.ConnectionDriverName</name>
  <value>com.mysql.jdbc.Driver</value>
  <description>Driver class name for a JDBC metastore</description>
</property>
property>
  <name>javax.jdo.option.ConnectionUserName</name>
 <value>hive</value>
</property>
                                           Utilisateur et mot de passe.
cproperty>
  <name>javax.jdo.option.ConnectionPassword</name>
  <value>cloudera</value>
</property>
                  HiveServer/ Driver communique avec le Metastore Service distant via l'API Thrift
cproperty>
 <name>hive.metastore.uris</name>
 <value>thrift://127.0.0.1:9083</value>
 <description>IP address (or fully-qualified domain name) and port of the metastore host</description>
</property>
```

## Hive en ligne de commandes

• La commande hive:

```
[cloudera@quickstart ~]$ hive

Logging initialized using configuration in file:/etc/hive/conf.dist/hive-log4j.properties

WARNING: Hive CLI is deprecated and migration to Beeline is recommended.

hive>
```

La commande beeline :

```
[cloudera@quickstart ~]$ beeline

Beeline version 1.1.0-cdh5.13.0 by Apache Hive

beeline> !connect jdbc:hive2://localhost:10000

scan complete in 3ms

Connecting to jdbc:hive2://localhost:10000

Enter username for jdbc:hive2://localhost:10000: hive

Enter password for jdbc:hive2://localhost:10000: ********

Connected to: Apache Hive (version 1.1.0-cdh5.13.0)

Driver: Hive JDBC (version 1.1.0-cdh5.13.0)

Transaction isolation: TRANSACTION REPEATABLE_READ

0: jdbc:hive2://localhost:10000> ■
```

• La BD utilisée par défaut est default

## Hive en ligne de commandes

- hive est un client basé sur Apache-Thrift et Beeline est un client JDBC.
- La commande **hive** se connecte **directement** aux pilotes Hive (**Driver**), ce qui nécessite l'installation de la bibliothèque Hive **sur le poste client**.
- **beeline** se connecte à **hiveserver** via des <u>connexions JDBC</u> sans installer les bibliothèques Hive sur le poste client. On peut donc exécuter <u>beeline</u> à distance depuis l'extérieur du cluster.

Opération	beeline	hive
Se connecter au hiveserver	!connect jdbc_url	
Lister les tables	!table	show tables ;
	show tables ;	
Lister les colonnes	<b>!column</b> table_name	desc table_name;
	desc table_name;	
Exécuter une requête	select * from table_name;	select * from table_name;
Sauvegarder les commandes et leurs résultats dans un fichier.	!record result_file.txt	
	!record	
Exécuter une commande shell	!sh ls	! ls ;
Exécuter une commande dfs	dfs -ls;	dfs -ls;
Exécuter un script hql	!run hql_query_file.hql	source hql_query_file.hql;
Quitter le shell hive	!quit	quit;
Choix d'une BD	!connect jdbc_url	use database_name;

# Hive: Les types de données dans Hive

Primitive type	Description	Example
INT	It has 4 bytes, from -2, 147, 483, 648 to 2, 147, 483, 647.	10
BIGINT	It has 8 bytes, from -9, 223, 372, 036, 854, 775, 808 to 9, 223, 372, 036, 854, 775, 807. The postfix is L.	100L
FLOAT	This is a 4 byte single-precision floating-point number, from 1.40129846432481707e <sup>-45</sup> to 3.40282346638528860e <sup>+38</sup> (positive or negative). Scientific notation is not yet supported. It stores very close approximations of numeric values.	1.2345679
DOUBLE	This is an 8 byte double-precision floating-point number, from 4.94065645841246544e <sup>-324d</sup> to 1.79769313486231570e <sup>+308d</sup> (positive or negative). Scientific notation is not yet supported. It stores very close approximations of numeric values.	1.2345678901234567
BINARY	This was introduced in Hive 0.8.0 and only supports CAST to STRING and vice versa.	1011
BOOLEAN	This is a TRUE or FALSE value.	TRUE

# Hive: Les types de données dans Hive

STRING	This includes characters expressed with either single quotes (') or double quotes ("). Hive uses C-style escaping within the strings. The max size is around 2 G.	'Books' or "Books"
CHAR	This is available starting with Hive 0.13.0. Most UDF will work for this type after Hive 0.14.0. The maximum length is fixed at 255.	'US' or "US"
VARCHAR	This is available starting with Hive 0.12.0. Most UDF will work for this type after Hive 0.14.0. The maximum length is fixed at 65, 355. If a string value being converted/assigned to a varchar value exceeds the length specified, the string is silently truncated.	'Books' or "Books"
DATE	This describes a specific year, month, and day in the format of YYYY-MM-DD. It is available starting with Hive 0.12.0.  The range of dates is from 0000-01-01 to 9999-12-31.	
TIMESTAMP	This describes a specific year, month, day, hour, minute, second, and millisecond in the format of YYYY-MM-DD HH:MM:SS[.fff]. It is available starting with Hive 0.8.0.	2013-01-01 12:00:01.345

# Hive: Les types de données dans Hive

Complex type	Description	Example
ARRAY	This is a list of items of the same type, such as [val1, val2, and so on]. You can access the value using array_name[index], for example, fruit[0]="apple". Index starts from 0.	["apple","orange","mango"]
MAP	This is a set of key-value pairs, such as {key1, val1, key2, val2, and so on}. You can access the value using map_name[key] for example, fruit[1]="apple".	{1: "apple",2: "orange"}
STRUCT	This is a user-defined structure of any type of field, such as {val1, val2, val3, and so on}. By default, STRUCT field names will be col1, col2, and so on. You can access the value using structs_name.column_name, for example, fruit.col1=1.	{1, "apple"}
NAMED STRUCT	This is a user-defined structure of any number of typed fields, such as {name1, val1, name2, val2, and so on}. You can access the value using structs_name.column_name, for example, fruit.apple="gala".	{"apple":"gala","weight kg":1}
UNION	This is a structure that has exactly any one of the specified data types. It is available starting with Hive 0.7.0. It is not commonly used.	{2:["apple","orange"]}

### Hive: Créer une BD

- Une BD dans Hive décrit une collection de tables.
- Si la BD existe, on n'aura pas un message d'erreur.
- On crée une BD avec: **CREATE DATABASE** [**IF NOT EXISTS**] *db\_name* ;
- Lorsqu'on crée une nouvelle BD, Hive lui crée un nouveau sous-répertoire dans /user/hive/warehouse.
   Création de: /user/hive/warehouse/emi19.db
- Exemple: hive> CREATE DATABASE emi19;
- DATABASE a l'alias SCHEMA dans HQL:

**CREATE SCHEMA [IF NOT EXISTS]** db\_name;

• Exemple:

hive> CREATE SCHEMA IF NOT EXISTS emi19;

• Créer une BD en précisant le chemin du dossier et de la description de la BD:

hive> CREATE DATABASE IF NOT EXISTS db\_name

hive > **COMMENT** ' description '

hive > **LOCATION** ' hdfs\_directory ';

# Hive: Description et Suppression de BD

- Afficher les BDs existantes: **SHOW DATABASES**;
- Récupérer les meta-données d'une BD: **DESCRIBE DATABASE** nom\_bd;
- Choisir la BD à utiliser: **USE** nom\_bd;
- Connaitre la BD courante: **SELECT current\_database()**;
- Supprimer une BD:

```
DROP DATABASE IF EXISTS nom_bd; -- échec si la BB n'est pas vide
DROP DATABASE IF EXISTS nom_bd CASCADE; -- supprime la BD et les tables
```

- Afficher la liste des tables de la BD courante: **SHOW TABLES**;
- Afficher l'instruction de création d'une table existante: **SHOW CREATE TABLE** nom\_table;
- Afficher la structure d'une table :

```
DESCRIBE | DESC [nom_bd.]nom_table;
```

```
DESCRIBE | DESC FORMATTED [nom_bd.]nom_table; -- pour avoir plus de détails
```

- Supprimer une table: **DROP TABLE** *nom\_table* ;
- Vider une table: **TRUNCATE TABLE** *nom\_table* **;** *-- juste pour une table interne*.

### **HIVE: Les tables**

- La BD default est utilisée par défaut lorsqu'on se connecte à hive.
- Chaque table est **mappée** sur un répertoire qui se trouve par défaut sous /user/hive/warehouse dans HDFS. Par exemples:

/user/hive/warehouse/empl est créé pour la table empl de la BD default

/user/hive/warehouse/emi19.db/empl est créé pour la table empl de la BD emi19

- Toutes les données de la table seront stockées dans ce répertoire
- Ce type de table s'appelle une table interne ou une table gérée (Managed Table)
- Lorsque les données sont **déjà** stockées dans HDFS, une table **externe** peut être créée pour décrire ces données (*pointer sur ces données*).
- Lorsqu'une table **interne** est supprimée, ses **données** et ses **métadonnées** sont <u>supprimées</u> ensemble.
- Lorsque la table externe est supprimée, seules ses métadonnées sont supprimées. Les données
  ne sont pas supprimées. Ceci est très utile lorsque ces données sont partagées avec d'autre
  outils (Pig, ...).

### Hive: Création de table

• CREATE [EXTERNAL] TABLE [IF NOT EXISTS] [db\_name.] table\_name

```
(col_name data_type [COMMENT 'col_comment'], ...)
[COMMENT 'table_comment']
[ROW FORMAT row_format]
[STORED AS file_format]
[PARTITIONED BY (col_name data_type)]
```

- **EXTERNAL**: si on supprime la table, ses données ne seront pas supprimées de HDFS.
- IF NOT EXISTS: la table sera créée si elle n'existe pas.
- COMMENT: on associe un commentaire à la table ou à une colonne.
- ROW FORMAT: on précise le format de chaque ligne Par défaut, les champs sont délimités par (^A) '\001'

Exemple: DELIMITED FIELDS TERMINATED BY '|' LINES TERMINATED BY '\n'

• STORED AS: on indique le format du fichier de données relatif à la table.

**Exemple: TEXTFILE, SEQUENCEFILE, PARQUET, AVRO, RCFILE, ORC** 

• PARTITIONED BY: on partitionne les fichiers de données de la table selon une ou plusieurs colonnes.

Soit temp.csv un fichier contenant des mesures de températures Exemple 1:

```
Use emi19;
                                                            2011;41;3
                                                            2011;20;3
CREATE TABLE IF NOT EXISTS temperature
                                                            2012;31;3
            COMMENT 'année de mesure ',
( Year
       int
                                                            2012;34;3
  Т
       int COMMENT 'température enregistrée',
                                                            2012;35;3
       int COMMENT 'Catégorie'
COMMENT 'table des températures enregistrées par année et catégorie'
ROW FORMAT DELIMITED
```

FIELDS TERMINATED BY '\;'

STORED AS TEXTFILE;

```
hive> describe temperature;
0K
             int année de mesure
year
                    température enregistrée
             int
                    Catégorie
             int
```

```
hive> desc formatted temperature;
# col name
                     data type
                                            comment
                                            année de mesure
vear
                      int
                      int
                                            température enregistrée
                                            Catégorie
                      int
# Detailed Table Information
Database: emi19
                      cloudera
Owner:
                   Sun Mar 31 04:13:39 PDT 2019
CreateTime:
LastAccessTime:
                     UNKNOWN
Protect Mode:
                      None
Retention:
                   hdfs://quickstart.cloudera:8020/user/hive/warehouse/emsi19.db/temperature
Location:
                    MANAGED_TABLE
Table Type:
Table Parameters:
      COLUMN STATS ACCURATE true
               table des températures enregistrées par année et catégorie
      comment
```

MAP KEYS TERMINATED BY ':'

STORED AS TEXTFILE;

```
Exemple 2: Le fichier empl.txt contient des informations sur des employés:
       Amini Saad Morocco, Algeria Male, 30 DB: 80 Product: Developer Lead
       Salhi Anas Morocco Male, 35 Perl: 85 Product: Lead, Test: Lead
       Faridi Amal Egypte Female, 27 Python: 80 Test: Lead, COE: Architect
       Bellal Hafsa Tunisia Female, 57 Sales: 89, HR: 94 Sales: Lead
         TABLE IF NOT EXISTS empl
CREATE
             STRING,
( nom
             ARRAY<STRING> COMMENT 'lieu de travail',
 lieu_t
             STRUCT<sexe:STRING,age:INT>,
 sexe_age
 comp_score MAP<STRING,INT> COMMENT 'compétence et score',
 depart_role MAP<STRING,STRING> COMMENT 'département et rôles'
  ROW FORMAT DELIMITED FIELDS TERMINATED BY '|'
  COLLECTION ITEMS TERMINATED BY ','
```

```
hive> desc formatted empl;
# col name
                          data type
                                                     comment
                          string
nom
                                                     lieu de travail
lieu t
                          array<string>
                          struct<sexe:string,age:int>
sexe age
                         map<string,int> compétence et score
map<string,string> département et rôles
comp score
depart role
# Detailed Table Information
Database:
                       emsi19
Owner:
                       cloudera
CreateTime:
                       Sun Mar 31 04:46:30 PDT 2019
LastAccessTime:
                       UNKNOWN
Protect Mode:
                       None
Retention:
Location:
                      hdfs://quickstart.cloudera:8020/user/hive/warehouse/emsi19.db/empl
Table Type: MANAGED TABLE
Table Parameters:
        transient lastDdlTime 1554032790
 Storage Desc Params:
         colelction.delim
          field.delim
          mapkey.delim
          serialization.format
```

## Hive: Chargement de données dans une table interne

LOAD DATA [LOCAL] INPATH 'filepath' [OVERWRITE] INTO TABLE tablename;

#### **Exemple:**

**LOAD DATA INPATH** '/user/cloudera/hive\_lab/data/empl.txt'**INTO TABLE** empl;

→ Le fichier HDFS sera supprimé après le chargement (il est déplacé)

<u>N.b:</u> On peut copier (**hdfs dfs –cp** ) le fichier **empl.txt** directement dans le dossier de la table /**user/warehouse/emsi19/empl** 

LOAD DATA LOCAL INPATH '/home/cloudera/tp/hive/empl.txt' INTO TABLE empl;

LOAD DATA LOCAL INPATH '/home/cloudera/tp/hive/empl.txt' OVERWRITE INTO TABLE empl;

→ La table (interne ou externe) sera vidée avant le chargement

```
Exemple 1:
               Soit temp.csv un fichier contenant des mesures de températures
Use emi19;
CREATE EXTERNAL TABLE IF NOT EXISTS temperature
             COMMENT 'année de mesure ',
( Year
       int
  T
        int COMMENT 'température enregistrée',
        int COMMENT 'Catégorie'
COMMENT 'table des températures enregistrées par année et catégorie'
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\;'
LOCATION '/user/cloudera/hive/data/db'; -- dossier contenant les fichiers de données
                                          -- s'il n'existe pas, il sera crée.
-- Si la clause Location n'est pas indiquée, les fichiers de données seront stockés dans
/user/hive/warehouse/emi19/temperature
```

# Hive: chargement de données dans une table externe

#### **Shell Linux**

hdfs dfs -put /home/cloudera/tp/hive/empl.txt /user/cloudera/hive/data/db

#### **Shell Hive**

LOAD DATA LOCAL INPATH '/home/cloudera/tp/hive/empl.txt' INTO TABLE empl;

### **Hive: Atelier 1**

- 1. Dans un terminal, lancer la commande: hive
- 2. Créer la BD *analyse*: hive> CREATE DATABASE *analyse*
- 3. Lister le contenu du dossier HDFS: /user/hive/warehouse
- 4. Utiliser de la BD *analyse* : **hive**> **Use** *analyse*
- 5. Créer la table *vol1* (*year, month, day, fl, dep, arr, distance*)

#### hive> CREATE TABLE vol1

(year INT, month INT, day INT, fl STRING, dep STRING, arr STRING, distance INT)

# ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;'

- STORED AS TEXTFILE;
- 6. Afficher la liste des tables de la BD courante.
- 7. Consulter le **Metastore** pour avoir le schéma de la table **vol1**: **hive> DESCRIBE** *vol1* ;
- 8. Charger le fichier **local vol.csv** dans la table *vol1* en utilisant la commande *LOAD*
- 9. Consulter de la table: **hive**> **SELECT** *year*, dep, **COUNT**(*fl*)

FROM vol1

**GROUP BY** dep, year;

N.B: Remarquez les jobs Map-Reduce crées.

### **Hive: Atelier 1**

- 10. Créer la table **externe** *vol2* (*year, month, day, fl, dep, arr, distance*) en indiquant son dossier HDFS de données qu'il faut créer, par exemple: /user/cloudera/hive/data/db
- 11. Copier le fichier local vol.csv dans le dossier HDFS: /user/cloudera/hive/data/db
- 12. Effectuer une requête HQL sur la table *vol2*.
- 13. Charger le fichier local **vol.csv** dans la table **vol2** avec **LOAD** et sans l'option **overwrite**.
- 14. Lister le contenu du dossier HDFS: /user/cloudera/hive/data/db
- 15. Afficher les métadonnées détaillées de la table vol2.
- 16. Exécuter séparément les deux requêtes: SELECT \* FROM vol2;

SELECT year, dep, COUNT(fl)

FROM vol1

GROUP BY dep, year;

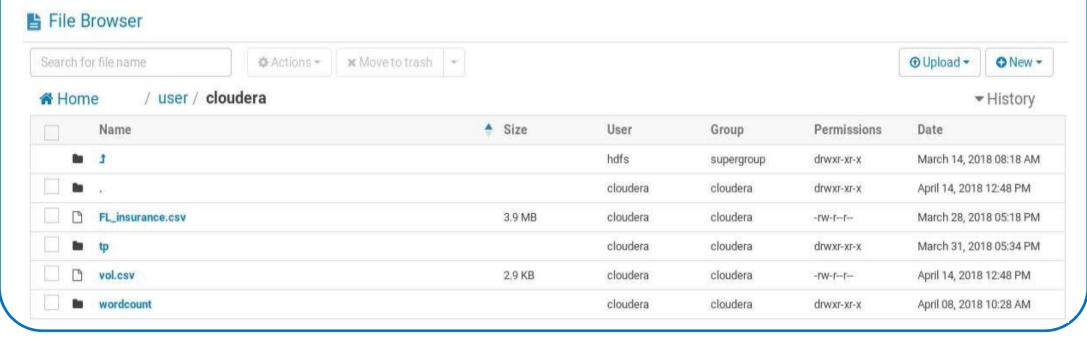
Quelle est la différence entre les deux lors de leur exécution?

### **Hive: Atelier 1**

- 17. Créer la table interne vol3 (year, month, day, fl, dep, arr, distance).
- 18. Charger le contenu de la table *vol2* dans la table *vol3*.
- 19. Effectuer une requête HQL (Select ....) sur la table *vol2*. Qu'obtient-on? Pourquoi?
- 20. Lister le contenu du dossier de la table *vol2* Comment il est? Pourquoi?

### Hive: Gérer les données avec Apache Hue (Hadoop User Experience)

- Interface web donnant accès aux données stockées dans HDFS.
- Hue est configuré pour répondre sur le port 8888.
- Hue permet de visualiser l'arborescence HDFS et le **metastore** de Hive.
- L'URL sur la VM Cloudera: <a href="http://10.0.2.15:8888">http://10.0.2.15:8888</a>
- Login/mot de passe = cloudera/cloudera
- Le raccourci **= /Files** permet de visualiser l'arborescence HDFS



### Hive: Gérer les données avec Apache Hue (Hadoop User Experience)

- L'éditeur Hive est accéssible via l'URL: <a href="http://10.0.2.15:8888/hue">http://10.0.2.15:8888/hue</a>
- Cliquer sur le lien (à gauche de l'interface Hue) plusieurs fois jusqu'à avoir **Sources**

default

- Cliquer sur **Hive** pour avoir accès aux BD déjà créées.
- Cliquer sur la BD **analyse** pour avoir ses tables
- Cliquer sur le raccourci + pour créer une nouvelle table.
- Remplir les champs comme suit puis cliquer sur **Next**:



### Hive: Gérer les données avec Apache Hue (Hadoop User Experience)

• Remplir les champs comme suit

Name: analyse.vol

Format: Text

Fields: year:int, month:int, day:int, flight:string, depart:string,

destination:string, distance:int

- Cliquer sur **Submit**
- Les détails de la table créée seront affichés: Databases > default > vol
- Choisir: Query /Editor /Hive
- Saisir la requête suivante puis cliquer sur le petit triangle bleu pour l'exécuter:

```
SELECT flight, depart, destination, distance
FROM vol
WHERE depart like 'I%'
ORDER BY depart
```

• Refaire la même chose pour:

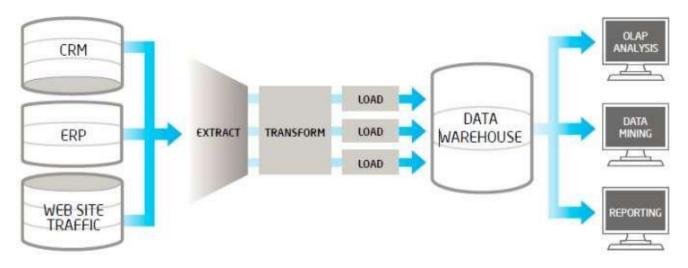
```
SELECT depart, count(depart) as Nb_Vol
FROM vol
WHERE depart like 'I%'
GROUP BY depart
ORDER BY depart
```

# **Hive: Format de fichiers**

- Les formats de représentation de données utilisés en Big Data sont très variés:
  - □ Formats de stockage **en lignes** ou enregistrements:
    - Fichiers plats / fichiers texte
    - CSV et fichiers délimités
    - JSON
    - SequenceFile
    - Avro
    - Autres formats: XML, YAML
  - □ Formats de stockage **orientés colonnes**:
    - RC (Record Columnar File) /ORC (Optimized Row Columnar File)
    - Parquet
- Librairies de compression des données

# Fichier Plat/Fichier texte

• Le processus **ETL** (Extract-Transform-Load) traditionnel extrait les données de plusieurs sources, les nettoie, les formate et les charge dans un entrepôt de données pour des besoins d'analyse.



- Les fichiers plats ou texte doivent être structuréset traités sous forme de champs (attributs):
  - □ Les champs peuvent être à des positions fixées dans des enregistrements
  - □ Ou, l'analyse textuelle peut être nécessaire pour extraire le sens.
- Généralement en Big Data, on charge les données dans leur état brut.

# CSV et fichiers délimités

Format utilisé dans les tableurs (Excel, ...): ☐ Chaque ligne correspond à un enregistrement. ☐ Les colonnes d'une ligne sont séparées par une virgule (ou autre délimiteur: tabulation, |, ; , ...) ☐ On peut avoir une ligne d'en-tête avec des noms de colonnes • Problèmes: ☐ Des caractères d'échappement peuvent être présents (backslash = \) ☐ Windows et Linux utilisent différents caractères de fin de ligne Python a une bibliothèque standard qui inclut un package CSV • Le capacités des formats CSV sont limitées: ☐ Suppose que chaque enregistrement a un nombre fixe d'attributs ☐ Pas facile de représenter des ensembles, des listes, des maps ou des structures de données plus complexes

# JSON: JavaScript Object Notation

- JSON est un format de sérialisation d'objets en texte brut qui peut représenter des données assez complexes pouvant être transférées entre utilisateur/programme ou programme/programme
- Souvent appelé le langage du Web 2.0
- Deux structures de base:
  - □ *Enregistrements* constitués de map (paires *clé/valeur*), entre accolades: {nom: "John", âge: 25 ans}
  - $\square$  Les *listes* (*tableaux*) sont entre crochets: [...]
- Les enregistrements et les tableaux peuvent être imbriqués

- Les bibliothèques supportant JSON sont disponibles dans R, Python, ...etc
- Il y a beaucoup d'API qui renvoient des données JSON: Google Geocoder, Twitter, Yahoo Answers, ... etc.

# SequenceFile

- Représentation **binaire** de pairs *clé/valeur*
- Orienté ligne (enregistrements)
- Utilisé pour le transfert de données entre les jobs Map et Reduce.
- Permet de spliter les données, pour les job Map, même compressées.
- La lecture de données dans le format **SequenceFile** est plus performante que celle des fichiers textes plats (*pas besoin de structuration d'enregistrements*)
- Ce format a une implémentation uniquement en Java où plusieurs classes permettent de lire, écrire ou trier.
- Il y a trois choix de compression de fichier **SequenceFile**:
  - 1.NONE: Enregistrements *clé/valeur* non compressés.
  - **2.RECORD**: Enregistrements *clé/valeur* compressés: seules les valeurs sont compressées
  - **3.BLOCK**: Bloc d'enregistrements *clé/valeur* compressés: les clés et les valeurs sont collectées dans des «blocs» séparément et compressées. La taille du 'bloc' est configurable par **io.seqfile.compress.blocksize** dans **core-site.xml** (valeur par défaut: 1000000 Octets)

# Avro



- Le format **Avro** permet de stocker les fichiers sous format **binaire** permettant l'interopérabilité d'applications écrites en différents langages de programmation · **Avro** est **indépendant** des langages de programmations.
- Avro est orienté ligne (enregistrement) dont le schéma est codé en JSON dans le fichier lui-même.
- Les blocs de fichiers Avro peuvent être compressés et splitables.
- Avro supporte l'évolution de schéma (versioning) : par exemple, si des colonnes sont ajoutées ou supprimées d'une table, les fichiers de données précédemment importés peuvent être traités avec les nouveaux.

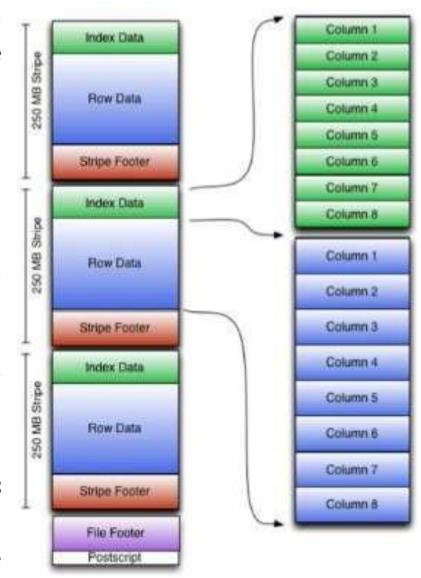
# Record Columnar File (RC)

- RCFile (Record Columnar File) est le premier format "colonne" adopté par Hadoop et utilisé initialement dans Hive.
- <u>Objectif</u>: <u>chargement rapide</u> des données, <u>exécution rapide</u> des requêtes et une <u>utilisation très efficace de l'espace de stockage</u>.
- Colonnes stockées séparément en format binaire.
- · Lecture et décompression des colonnes désirées.
- RC applique une compression par colonne sur des groupes de lignes.
- Le format RC est un format tabulaire constitué de lignes et de colonnes.
- Les tables sont stockées dans HDFS: des groupes de lignes sont stockés dans des blocs HDFS.

## Optimized Row Columnar (ORC)

Le format ORC (Optimized Row Columnar) désigné comme successeur du format RC en proposant une approche optimisée de compression plus efficace:

- ☐ Un fichier ORC contient des **bandes** (**stripes**) de données de ligne
- ☐ Taille de **bandes** par défaut 256 Mo et peut être plus grande.
- ☐ Les données d'index se composent de valeurs minimales et maximales pour chaque colonne, ainsi que les positions de ligne dans chaque colonne.
- ☐ L'indexation permet de sauter des blocs entiers de rangées ne répondant pas à une requête.
- ☐ Le **pied** de bande contient l'encodage de chaque colonne.
- ☐ À la **fin** du fichier, un **postscript** contient les paramètres de compression.
- ☐ Algorithmes (codecs: Snappy, GZIP, BZIP2, ...) de compression **spécifiques pour différents types de colonnes.**



# **Parquet**

- Apache Parquet est un format de stockage en colonnes compressées (développé par Cloudera et Twitter)
- Il a les mêmes caractéristiques que ORC:
  - ☐ Groupement de lignes avec un stockage et compression par colonne
  - ☐ Supporte les évolutions de schéma.
- Il est compatible avec toutes les interfaces **MapReduce** comme **Java**, **Hive**, **Pig** et d'autres moteurs d'exécution comme **Impala** ou **Spark**.
- Parquet supporte des structures de données complexes ainsi que la lecture et l'écriture par les APIs d'Avro.
- Fournit l'un des meilleurs résultats dans divers tests de performance de référence
- Le stockage en colonnes offre les avantages suivants:
  - ola compression est plus efficace car les données de colonne sont du même type.
  - OLe traitement des requêtes est plus efficace car les colonnes sont stockées ensemble.

### **HIVE: Table au format Avro** (avant la version 1.0)

• Création d'un fichier JSON sur HDFS contenant le schéma de la table: { "type" : "record", "name": "nom\_schema", "namespace": "namespace\_schema", "fields": [ "name": "nom champ", "type": "type champ", "default": "val\_défaut | NONE", "**doc**" : "*comment*"}, **Exemple**: Le fichier HDFS '/user/cloudera/hive\_lab/schema\_avro/temperature.avsc' "type": "record", "name": "temperature", "namespace": "avro.google.com", "fields" : [{"name" : "**year**","type" : "int","default" : "1800", "doc" : "*année d'enregistrement*"}, {"name" : "T", "type" : "int", "default" : "999", "doc" : "température enregistrée"}, {"name" : "**C**","type" : "int","default" : "-1", "doc" : "*catégorie*"}

## **HIVE: Table au format Avro** (avant la version 1.0)

Classe	Description	Utilisée dans la clause
org.apache.hadoop.hive.serde2.avro.AvroSerDe	La classe Hive SerDe pour le stockage de données au format Avro	ROW FORMAT SERDE
org.apache.hadoop.hive.ql.io.avro. <mark>AvroContainerInputFormat</mark>	Format de données en entrée d'un conteneur Avro.	STORED AS
org.apache.hadoop.hive.ql.io.avro.AvroContainerOutputFormat	Format de données de sortie d'un conteneur Avro.	STORED AS

• La clause **TBLPROPERTIES** de la commande **CREATE EXTERNAL TABLE** permet de spécifier le **schéma** de la table si les données de la table sont stockées au format Avro (ou autre: ORC, ....).

CREATE EXTERNAL TABLE IF NOT EXISTS nom\_table

**ROW FORMAT SERDE** 'org.apache.hadoop.hive.serde2.avro.AvroSerDe'

STORED AS INPUTFORMAT 'org.apache.hadoop.hive.ql.io.avro.AvroContainerInputFormat'

**OUTPUTFORMAT** 'org.apache.hadoop.hive.ql.io.avro.AvroContainerOutputFormat'

**TBLPROPERTIES** ('avro.schema.url'='hdfs\_directorylfichier\_schéma.avsc');

## **HIVE: Table au format Avro** (avant la version 1.0)

• Exemple:

CREATE EXTERNAL TABLE IF NOT EXISTS temperature\_avro

ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.avro.AvroSerDe'

STORED AS INPUTFORMAT 'org.apache.hadoop.hive.ql.io.avro.AvroContainerInputFormat'

**OUTPUTFORMAT** 'org.apache.hadoop.hive.ql.io.avro.AvroContainerOutputFormat'

**LOCATION** '/user/cloudera/hive\_lab/data/db\_avro'

TBLPROPERTIES ('avro.schema.url'='/user/cloudera/hive\_lab/schema\_avro/temperature.avsc');

#### **HIVE: Table au format Avro**

• A partir de la version Hive 1.0:

```
CREATE EXTERNAL TABLE nom_table (.....)
```

STORED AS AVRO

**LOCATION** 'hdfs\_directory';

• Chargement de données (fichiers) au format Avro avec l'instruction LOAD DATA.

**N.B**: Les fichiers Avro chargés doivent avoir le schéma de la table.

• Importation de données dans une table au format **Avro** à partir d'une autre table:

**INSERT OVERWRITE TABLE** table\_destination **SELECT** \* **FROM** [db\_name.]table\_source;

**Exemple**: **INSERT OVERWRITE TABLE** temperature\_avro **SELECT \* FROM** temperature ;

→ Un fichier binaire sera créé dans le dossier de données de la table dont le schéma sera stockée en format JSON dans l'entête du fichier.

## **HIVE:** Table au format Parquet

• Création d'une table externe au format Parquet

```
CREATE EXTERNAL TABLE [IF NOT EXISTS] nom_table (.....)

ROW FORMAT SERDE 'parquet.hive.serde.ParquetHiveSerDe'

STORED AS PARQUET

LOCATION 'hdfs_directory';
```

#### **Exemple**:

CREATE EXTERNAL TABLE IF NOT EXISTS temperature\_parquet

```
(Year int,
T int,
C int
```

**ROW FORMAT SERDE** 'parquet.hive.serde.ParquetHiveSerDe' **STORED AS PARQUET** 

**LOCATION** '/user/cloudera/hive\_lab/data/db\_parquet'

On importe des données dans la table avec INSERT OVERWRITE TABLE

1. Créer les dossiers HDFS suivants:

```
/user/cloudera/hive_lab/data/bank_txt
/user/cloudera/hive_lab/data/bank_avro
/user/cloudera/hive_lab/data/bank_parquet
```

N.B: Utiliser mkdir avec l'option p pour créer tous les dossiers avec une seule commande

hdfs dfs -mkdir -p /user/cloudera/hive\_lab/data/{bank\_txt,bank\_avro,bank\_parquet}

- Copier le fichier local bank-data.csv dans le dossier HDFS /user/cloudera/hive\_lab/data/bank\_txt
- 3. Créer la table externe **bank\_txt** stockée au format texte et dont:
  - les données sont dans le dossier HDFS /user/cloudera/hive\_lab/data/bank\_txt
  - les colonnes contiennent: id client (entier), âge (entier), sexe (texte), région (texte), revenu (, marié, enfants, voiture, hypothèque.
    - **N.B:** Visualiser le contenu du fichier CSV pour avoir le type de chaque colonne.
- 4. Consulter la table créée par une requête HQL.

- 5. Créer la table externe **bank\_avro** stockée au format **Avro** et dont le dossier de données est /user/cloudera/hive\_lab/data/bank\_avro
- 6. Importer dans la table bank\_avro les données de la table bank\_txt.
- 7. Lister (avec ls) les fichiers du dossier HDFS /user/cloudera/hive\_lab/data/bank\_avro
- 8. Afficher ( avec cat ) le contenu des fichiers de /user/cloudera/hive\_lab/data/bank\_avro
- 9. Créer la table externe **bank\_parquet** stockée au format **Parquet** et dont le dossier de données est /user/cloudera/hive\_lab/data/bank\_parquet
- 10. Importer dans la table **bank\_parquet** les données de la table **bank\_txt**.
- 11. Lister ( avec ls) les fichiers du dossier HDFS /user/cloudera/hive\_lab/data/bank\_parquet
- 12. Afficher ( avec cat ) le contenu des fichiers de /user/cloudera/hive\_lab/data/bank\_parquet
- 13. Ecrire des requêtes afin d'avoir à partir des **trois tables** :
  - a) La moyenne de revenu par région.
  - b) Le pourcentage des clients mariés et ayant une hypothèque.
  - c) Le nombre de clients mariés par région et ayant des enfants et une hypothèque
  - d) Les identifiants des clients ayant le revenu maximal.

- Par défaut, une requête HQL analyse **toute la table**. Cela ralentit les performances lors de l'interrogation d'une grande table.
- Ce problème pourrait être résolu en créant des partitions similaires à celles dans les SGBDR.
- Dans Hive, le partitionnement est effectué par une ou plusieurs colonnes.
- Chaque partition est mappée vers un sous-répertoire du répertoire de la table dans HDFS.
- Lorsque la table est interrogée, seules les partitions requises (*répertoires*) des données de la table sont lues afin de réduire le temps d'exécution de la requête et améliorer les performances.
- Chaque partition a son propre stockage (*répertoire*) et sa propre sérialisation (*format*)
- Exemple:

```
CREATE EXTERNAL TABLE temperature_partition

( -- colonnes régulières

T int , C int
)

-- colonnes de partitionnement

PARTITIONED BY (Year int)

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;'

STORED AS TEXTFILE

LOCATION '/user/cloudera/hive_lab/data/temperature_partition';
```

• La description de la table partitionnée fournit des informations sur le partitionnement effectuée

```
Exemple:
```

```
hive> desc temperature_partition;
OK

t int
c int
year int

# Partition Information
# col_name data_type comment

year int
```

- Par défaut, le partitionnement dynamique n'est pas activé.
- On utilise l'instruction ALTER TABLE ... ADD PARTITION pour ajouter des partitions

year=2011 vear=2013

**statiques** (*manuellement*) à une table.

Exemple:

**ALTER TABLE** temperature\_partition

**ADD PARTITION** (year=2011) **PARTITION** (year=2013);

```
[cloudera@quickstart ~]$ hdfs dfs -ls /user/cloudera/hive_lab/data/temperature_partition
Found 2 items
drwxr-xr-x - cloudera cloudera 0 2019-04-16 08:10 /user/cloudera/hive_lab/data/temperature_partition/year=2011
drwxr-xr-x - cloudera cloudera 0 2019-04-16 08:10 /user/cloudera/hive_lab/data/temperature_partition/year=2013
```

 La commande SHOW PARTITIONS permet d'avoir la liste des partitions actuelles dans une table partitionnée. Exemple: SHOW PARTITIONS temperature\_partition;

hive> show partitions temperature partition;

• On utilise l'instruction ALTER TABLE ... DROP PARTITION pour supprimer des partitions.

```
Exemple: ALTER TABLE temperature_partition

DROP IF EXISTS PARTITION (year=2011);
```

• On utilise l'instruction **TRUNCATE TABLE ... PARTITION** pour vider une partition d'une **table interne**.

Exemple: TRUNCATE TABLE temperature\_partition PARTITION (year=2011);

• On utilise l'instruction **hdfs dfs -rm** pour vider une partition d'une **table externe**. <u>Exemple</u>:

hdfs dfs -rm -f /user/cloudera/hive\_lab/data/temperature\_partition/year=2011/\*

• On peut activer le partitionnement **dynamique** afin que les partitions soient créées de manière dynamique à partir de valeurs de données insérées. [utiliser **Hive Shell** ou **hive-site.xml**]

hive>SET hive.exec.dynamic.partition=true;

hive>SET hive.exec.dynamic.partition.mode=nonstrict;

• On importe les données dans la table partitionnée dont les partitions seront créées dynamiquement.

Exemple: INSERT OVERWRITE TABLE temperature\_partition

**PARTITION** (year)

SELECT T, C, Year FROM temperature; --Attention à l'ordre des colonnes

N.B: la partition year=\_\_HIVE\_DEFAULT\_PARTITION\_\_\_
sera créée pour les enregistrement ayant year=NULL

Création dynamiques des partitions
selon les données importées

hive> show partitions temperature\_partition;
0K
year=2011
year=2012
year=2013
year=2014
year=2015

[cloudera@quickstart hive]\$ hdfs dfs -ls /user/cloudera/hive lab/data/temperature\_partition Found 5 items 0 2019-04-14 10:21 //user/cloudera/hive lab/data/temperature partition/year=2011 - cloudera cloudera drwxr-xr-x 0 2019-04-14 10:21 /user/cloudera/hive lab/data/temperature partition/year=2012 cloudera cloudera drwxr-xr-x 0 2019-04-14 10:21 /user/cloudera/hive lab/data/temperature partition/year=2013 cloudera cloudera drwxr-xr-x 0 2019-04-14 10:21 /user/cloudera/hive lab/data/temperature partition/year=2014 drwxr-xr-x - cloudera cloudera - cloudera cloudera 0 2019-04-14 10:21 /user/cloudera/hive lab/data/temperature partition/year=2015 drwxr-xr-x

• On peut charger des fichiers dans une partition spécifique d'une table partitionnée.

LOAD DATA INPATH '/user/cloudera/data/2012.txt' INTO TABLE temperature\_partition

PARTITION(year=2012);

Attention à l'ordre des colonnes dans 2012.txt

Modifier les propriétés d'une partition:

**ALTER TABLE** temperature\_partition **PARTITION** (year=2011) **SET FILEFORMAT** ORC;

Les anciennes données avec l'ancien format ne sont plus accessible avec Select.

**Exemple**: Select \* from temperature\_partition; → exception : Malformed ORC file....... Invalid postscript.)

ALTER TABLE temperature\_partition PARTITION (year=2011) SET LOCATION

'/user/hive\_lab/data';

**ALTER TABLE** temperature\_partition **PARTITION** (year=2011) **ENABLE NO\_DROP**;

Empêcher la suppression d'une partition

ALTER TABLE temperature\_partition PARTITION (year=2011) DISABLE NO\_DROP;

ALTER TABLE temperature\_partition PARTITION (year=2011) ENABLE OFFLINE;

L'accès aux données d'une partition offline générera une exception.

**Exemple**: Select \* From temperature\_partition ; → exception : Query against an offline table or partition

Table temperature\_partition Partition year=2011

**ALTER TABLE** temperature\_partition **PARTITION** (year=2011) **DISABLE OFFLINE**;

**ALTER TABLE** temperature\_partition **PARTITION** (year=2011) **CONCATENATE**;

La fusion est possible pour les partitions ayant le format RCFILE ou ORCFILE.

• On peut partitionner une table suivant plusieurs colonnes ce qui engendrera la création de plusieurs **dossiers** et **sous-dossiers**.

#### **Exemple**:

```
CREATE EXTERNAL TABLE temperature_partition2 ( T int )

PARTITIONED BY (Year int, C int)

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;' STORED AS TEXTFILE

LOCATION '/user/cloudera/hive_lab/data/temperature_partition2';

INSERT OVERWRITE TABLE temperature_partition2 PARTITION (Year, C)

SELECT T, Year, C FROM temperature; --Attention à l'ordre des colonnes

| hive> show partitions temperature_partition2;
```

```
hive> show partitions temperature_partition2;

OK

year=2011/c=1
year=2011/c=4
year=2011/c=9
year=2011/c=99
year=2012/c=1
year=2012/c=3
year=2012/c=4
year=2012/c=9
.....
```

• On aura un partitionnement de premier niveau effectué par Year et un deuxième effectué par C.

hdfs dfs -Is -R /user/cloudera/hive\_lab/data/temperature\_partition2

```
user/cloudera/hive lab/data/temperature partition2/year=2011
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=1
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=1/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=3
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=3/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=4
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=4/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=9
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=9/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2011/c=99
user/cloudera/hive lab/data/temperature partition2/year=2011/c=99/000000
/user/cloudera/hive lab/data/temperature partition2/year=2012
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=1
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=1/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=3
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=3/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=4
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=4/000000 0
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=9
/user/cloudera/hive lab/data/temperature partition2/year=2012/c=9/000000 0
```

Modifier les propriétés d'une partition multi-colonnes:

**ALTER TABLE** temperature\_partition2 **PARTITION** (year=2011, c=3) **SET FILEFORMAT** AVRO;

La sous-partition c=3 de la partition year=2011 aura le format AVRO

**ALTER TABLE** temperature\_partition2 **PARTITION** (year=2011,c=3) **ENABLE OFFLINE**;

La sous-partition c=3 de la partition year=2011 sera offline.

**ALTER TABLE** temperature\_partition2 **PARTITION** (c=3) **ENABLE OFFLINE**;

La sous-partition c=3 de **toutes** les partitions year sera offline.

- Le partitionnement fournit un moyen pour séparer les données d'une table Hive en plusieurs fichiers/répertoires. Cependant, cela ne donne de bonnes performances que dans peu de scénarios, comme:
  - Quand le nombre de partitions est limité.
  - Ou lorsque les partitions sont de taille relativement égale.
- Un grand nombre de partitions engendre un grand nombre de fichiers HDFS ce qui affecte considérablement les performances du **Namenode**.
- Hive propose le concept **Bucketing** qui est une autre technique pour décomposer les données de tables en parties plus faciles à gérer.
- Contrairement aux partitions, un **Bucket** (compartiment) correspond à un **fichier** HDFS.
- Le nombre de **Buckets** est défini par l'utilisateur lors de la création de la table
- Le **Bucketing** est effectué selon une **colonne** (ou plusieurs) dont la valeur sera **hachée** afin de déterminer le Bucket dans lequel chaque enregistrement doit être stocké.
- La meilleur façon de choisir les colonnes de Bcketing est d'identifier les colonnes les plus utilisés pour filtrer les enregistrement ou dans les jointures selon la logique métier.

- Exemple: Si on a un **Bucketing** par *idclient*, les enregistrements ayant le même *idclient* seront toujours stockés dans le même Bucket.
- La clause **CLUSTERED BY** permet de préciser les colonnes de Bucketing et le nombre de Buckets: **CLUSTERED BY** (nom\_colonne, ...) [SORTED BY (col1 [ASC|DESC], ...)]

  INTO nb\_buckets BUCKETS

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;'
STORED AS TEXTFILE

LOCATION '/user/cloudera/hive\_lab/data/temperature\_buckets';

- Activer le Bucketing avant l'importation des données : set hive.enforce.bucketing = true;
- Importation de données:

**INSERT OVERWRITE TABLE** temperature\_buckets **SELECT** \* **FROM** temperature;

```
[cloudera@guickstart ~] hdfs dfs -ls /user/cloudera/hive lab/data/temperature buckets
Found 2 items
                                     14948 2019-04-21 11:16 /user/cloudera/hive lab/data/temperature buckets/000000 0
-rwxr-xr-x 1 cloudera cloudera
                                     45865 2019-04-21 11:16 /user/cloudera/hive lab/data/temperature buckets/000001 0
            1 cloudera cloudera
- rwxr-xr-x
```

• Le compartiment (Bucket) de chaque enregistrement est détermine par :

**Hash**(val\_colonne(s)) MOD Nbre\_Buckets

on a Nbre\_Buckets =4, on aura quatre fichiers crées 000000\_0, 000001\_0, Exemple:

$$Hash(colonne(s)) MOD 4 = -$$

- stockage dans le fichier 000000\_0
- - stockage dans le fichier 000003\_0

- Pour pouvoir réaliser les opérations **Update** et **Delete** sur une table, elle doit être une **Bucketed** table au format **ORCFILE**.
- Les paramètres suivants doivent être positionnés dans hive-site.xml ou via le shell Hive:

```
SET hive support concurrency = true;
```

SET hive enforce bucketing = true;

SET hive exec.dynamic.partition.mode = nonstrict;

SET hive.txn.manager = org.apache.hadoop.hive.ql.lockmgr.DbTxnManager;

SET hive.compactor.initiator.on = true;

SET hive.compactor.worker.threads = 1;

1. Créer les dossiers HDFS suivants:

/user/cloudera/hive\_lab/data/bank\_partition

/user/cloudera/hive\_lab/data/bank\_bucket

/user/cloudera/hive\_lab/data/bank\_part\_bucket

N.B: Utiliser mkdir avec l'option p pour créer tous les dossiers et sous-dossiers avec une seule commande

hdfs dfs -mkdir -p /user/cloudera/hive\_lab/data/{bank\_partition,bank\_bucked,bank\_part\_bucket}

2. Créer la table interne temporaire bank\_temp stockée au format texte.

CREATE **TEMPORARY** TABLE **bank\_temp** (id string, age int, sexe string, region string, revenu double, marie string, enfant int, voiture string, hypotheque string)

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;'

STORED AS TEXTFILE;

3. Charger le fichier local **bank-data.csv** dans la table **bank\_temp**. Interroger la table **bank\_temp** par une requête HQL

- 4. Créer la table externe **bank\_partition** partitionnée par **région** et dont le dossier de données est /**user/cloudera/hive\_lab/data/bank\_partition**
- 5. Créer la table externe **bank\_bucket** ayant deux **Buckets** par la colonne **âge** triée dans l'ordre croissant. Le dossier de données est /**user/cloudera/hive\_lab/data/bank\_bucket**
- 6. Activer le partitionnement et le Bucketing automatique
- 7. Importer dans les table bank\_partition et bank\_bucket les données de la table bank\_temp.

FROM bank\_temp

INSERT OVERWRITE TABLE bank\_partition Partition(region) SELECT

id,age,sexe,revenu,marie,enfant,voiture,hypotheque,region

#### INSERT OVERWRITE TABLE bank\_bucket SELECT \*;

- 8. Lister (avec ls -R) le contenu du dossier HDFS /user/cloudera/hive\_lab/data/bank\_partition
- 9. Mettre hors ligne la partition **region=TOWN** de la table **bank\_partition**
- 10. Tester la requête: select \* from bank\_partition;
- 11. Rendre en ligne la partition region=TOWN de la table bank\_partition

- 12. Lister (avec ls) le contenu du dossier HDFS /user/cloudera/hive\_lab/data/bank\_bucket
- 13. Afficher chacun des deux fichiers de ce dossier.

Y a-t-il une valeur de la colonne âge qui apparaît dans les deux fichiers?

14. Créer la table externe **bank\_part\_bucket** partitionnée par **région** et chaque partition a **deux** Buckets par la colonne **âge** et triés par **âge** et **revenu**. Le dossier de données est /user/cloudera/hive\_lab/data/bank\_part\_bucket

```
CREATE EXTERNAL TABLE nom_table (.....)

PARTIONED BY (....)

CLUSTERED BY (....) SORTED BY (...) INTO ... BUCKETS ROW FORMAT ....

STORED AS ...

LOCATION ....;
```

- 15. Importer dans le table **bank\_part\_bucket** les données de la table **bank\_temp**.
- 16.Lister (avec ls -R) le contenu du dossier HDFS /user/cloudera/hive\_lab/data/bank\_part\_bucket
- 17. Visualiser le contenu de quelques fichiers de données.